# Overcoming Spectral Bias via Cross-Attention 实验报告

# 1D Poisson 方程求解的失败

对于 1D Poisson 方程的例子:

$$-\Delta u(x) = f(x), \quad x \in [-1, 1]$$

满足 Dirichlet 边界条件,真实解 $u(x)$ 为:

$$\sin(0.1\pi x) + 0.2\sin(\pi x) + 0.4\sin\left(\frac{100}{3}\pi x\right) + 0.6\sin\left(\frac{200}{3}\pi x\right) + \sin(100\pi x)$$

这个例子的求解难点在于,$f(x)$中,频率为$100\pi$的振幅为$(100\pi)^2$,而频率为$0.1\pi$的振幅为$(0.1\pi)^2$,相差了$10^6$数量级,导致训练过程中,高频部分的误差主导了损失函数,使得低频部分的误差无法得到有效优化,最终导致模型难以收敛到真实解。

# 1D Poisson 方程求解的失败

使用 NN-CA 单网络，傅里叶特征频率满足$\omega \sim \mathcal{N}(0, \sigma^{-2}), \sigma = 0.006$总特征数为 4096，单个 token 包含的特征维数$d_q = 256$,隐藏层层数 6，使用 Adam 优化器训练 5000 epoch,训练结果见右下图.

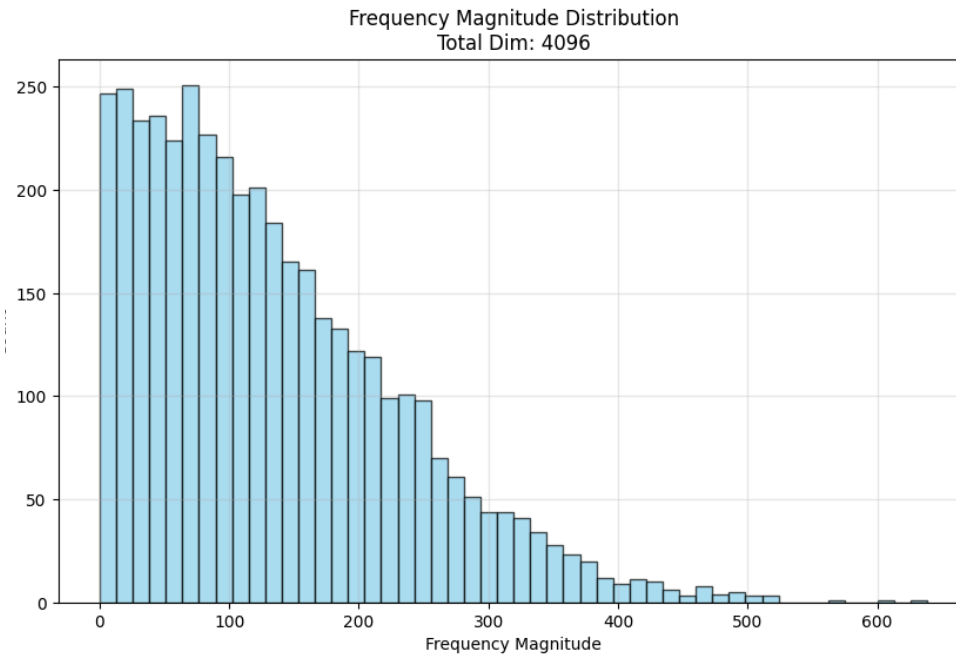


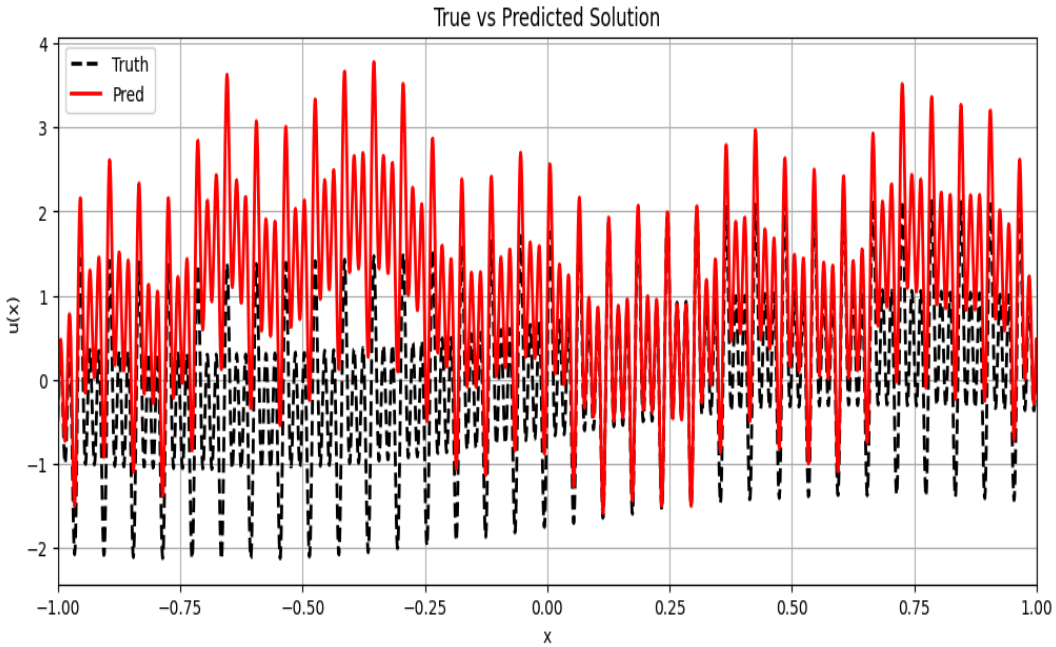

# 1D Poisson 方程求解的失败

可以看出，模型较好的捕捉了高频部分的特征，但在低频部分表现较差，难以收敛到真实解。

论文使用了一种双网络方法,在训练过程中,一个网络$u_l$专注于捕捉低频特征,另一个网络$u_h$专注于捕捉高频特征,最终预测为$u_h + \alpha u_l$.文中比较了$\alpha$恒定 0 或 1,可学习参数,和 Loss 函数对$\alpha$求导为 0 的极小值点$\alpha_{\text{opt}}$.其中$\alpha_{\text{opt}}$是每次迭代中用一些样本点计算得到的近似值,论文比较了四种方法得到的结果,发现可学习参数和$\alpha_{\text{opt}}$方法表现较好,而恒定 0 或 1 的方法表现较差。

然而在复现中，$u_l$的输出总是在很少几次训练后就恒为 0，导致双网络架构失去意义。经过多次实验，观察到$u_l$收敛于 0 的倾向在

# 1D Poisson 方程求解的失败

多组超参数下都存在,包括不同的学习率、不同的频率分布参数$\sigma$,不同的网络结构等。

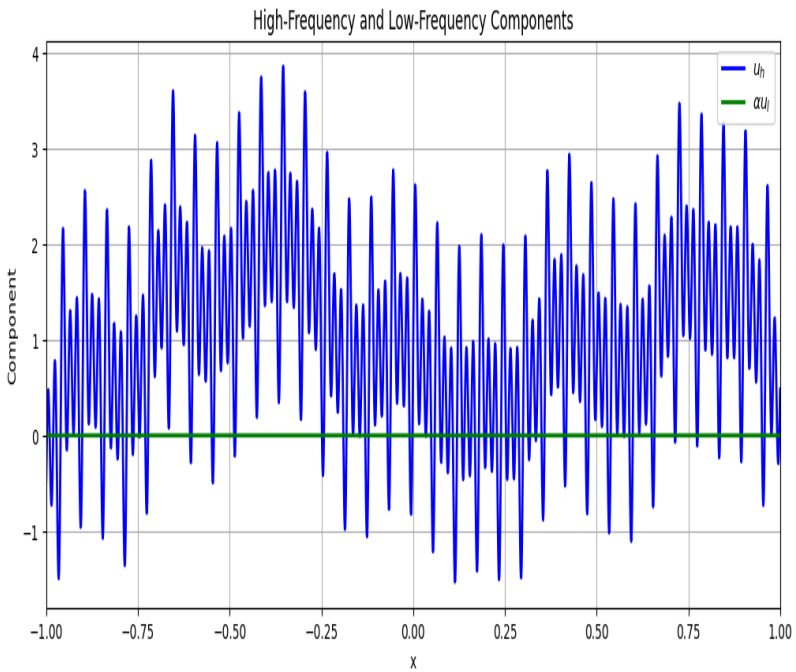


经过分析，这可能是由于训练过程中的边界条件在损失函数中加强太大导致的。论文中损失函数$L = L_f + \lambda L_b$，其中无论是$L_f$还是$L_b$,都混合了$u_h$和$u_l$，由于$L_f$的量级很大，论文中设置了$\lambda$为 1e3 或 1e4,原文中让$u_h$在边界处和满足原方程的 Dirichlet 条件，$u_l$在边界满足输出为 0 的 Dirichlet 条件，这本身就让$u_l$倾向于输出 0.

# 1D Poisson 方程求解的失败

而我们本来期待$u_l$学习的低频部分，如$\sin(0.1\pi x)$,在二阶导后的量级为$(0.1\pi)^2$,远小于高频部分的量级$(100\pi)^2$,因此模型倾向于忽略拟合低频部分，让$u_l$的输出恒为 0.

为了解决这个问题，有以下方法可以尝试:

- 解耦$L_b$中$u_h$和$u_l$的部分,让两部分有不同的权重,例如$L_b = \lambda_h L_{b(u_h)} + \lambda_l L_{b(u_l)}$,并且设置$\lambda_l$远小于$\lambda_h$,以减轻边界条件对$u_l$的影响。
- 不再让$u_l$在边界满足输出为 0 的 Dirichlet 条件,而是让$u_h + \alpha u_l$整体满足原始边界条件,这样可以让$u_l$有更多的自由度来学习低频部分。

# 1D Poisson 方程求解的失败

由于第二种方法超参数少而且似乎更加自然,我们首先尝试了第二种方法,并且在这种情景下重新推导了$\alpha_{\text{opt}}$的计算公式.结果证明了这个方法能解决$u_l$输出恒为 0 的问题.

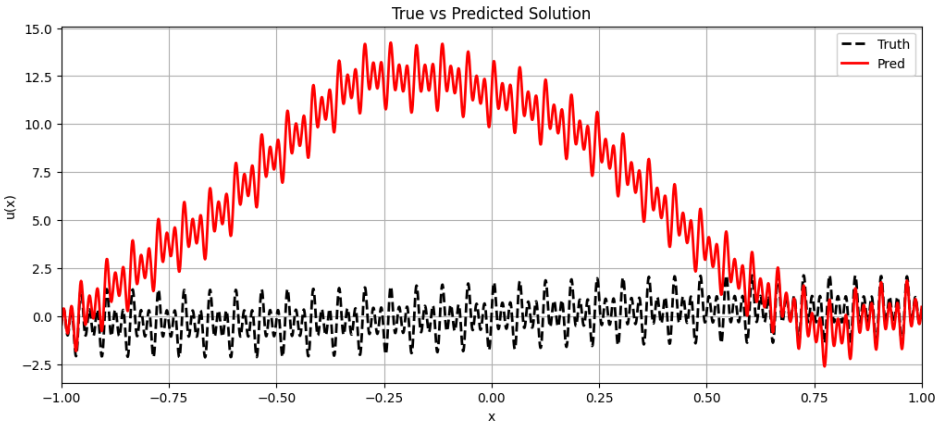


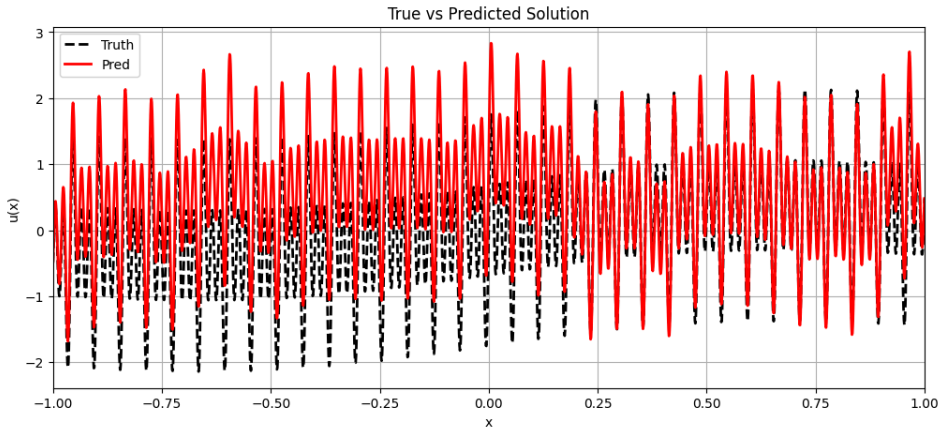


左图：令$\alpha$为$\alpha_{\text{opt}}$, 右图:令$\alpha$为可学习参数.

# 1D Poisson 方程求解的失败

然而该方法仍未解决模型在低频难以收敛到真实解的问题.另外，当使用原有公式计算$\alpha_{\text{opt}}$时，$\alpha$的值很快就趋近于 0 且无法回升，双网络没有效果；当使用新边界条件推导的公式计算$\alpha_{\text{opt}}$时，$\alpha$的值虽然不再趋近于 0，但训练表现不如设置$\alpha$为可学习参数的方法，这点和论文中$\alpha_{\text{opt}}$方法表现最好不一致。

# 1D Poisson 方程求解的失败

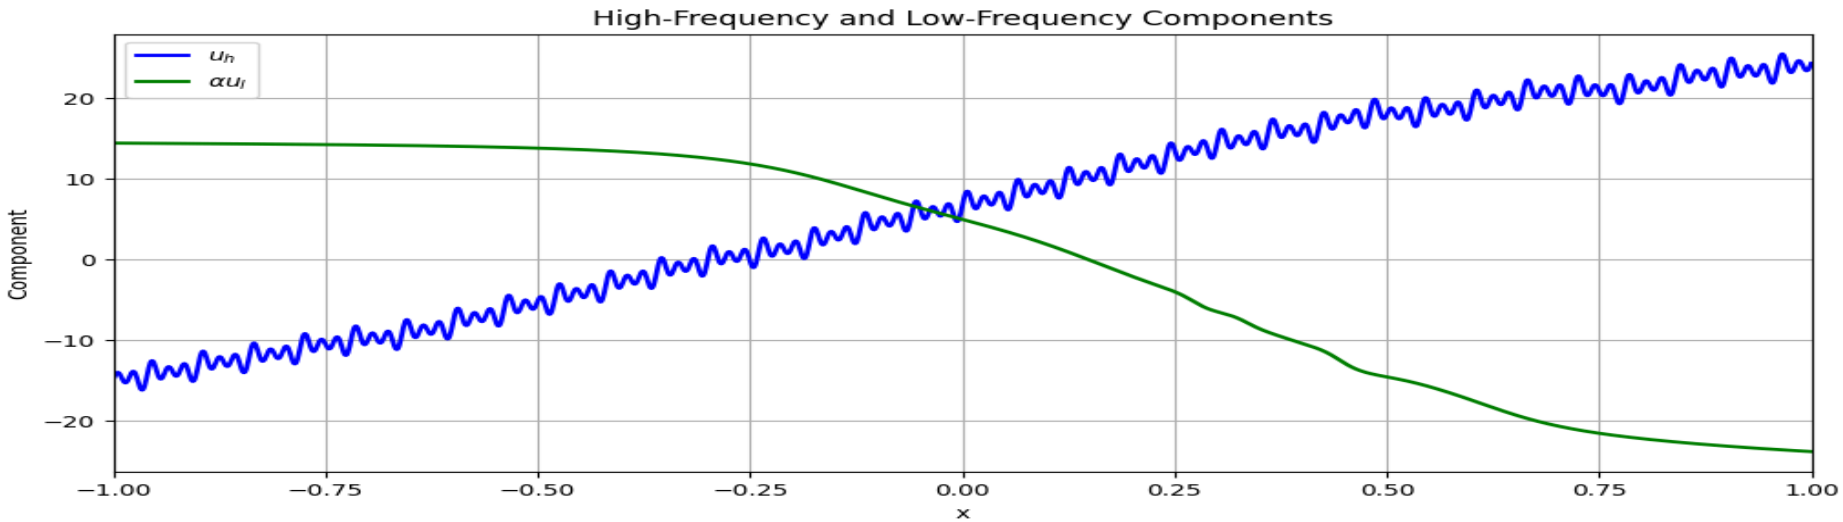


$\alpha = \alpha_{\text{opt}}$时的高低频分量

根据上图我们可以推测，在这种情况下，$\alpha u_b$的作用可能也只是和$u_h$相加满足边界条件，并没有真正起到分离高低频特征的作用，因此模型仍然难以收敛到真实解。

# 1D Poisson 方程求解的失败

和论文中平稳下降的 Error 曲线不同，我们的复现中 Error 曲线初期下降后几乎就不再下降了，这也说明模型在低频部分的拟合没有得到有效优化，无法进一步收敛到真实解。

后面两张图分别为论文和复现的结果。

# 1D Poisson 方程求解的失败

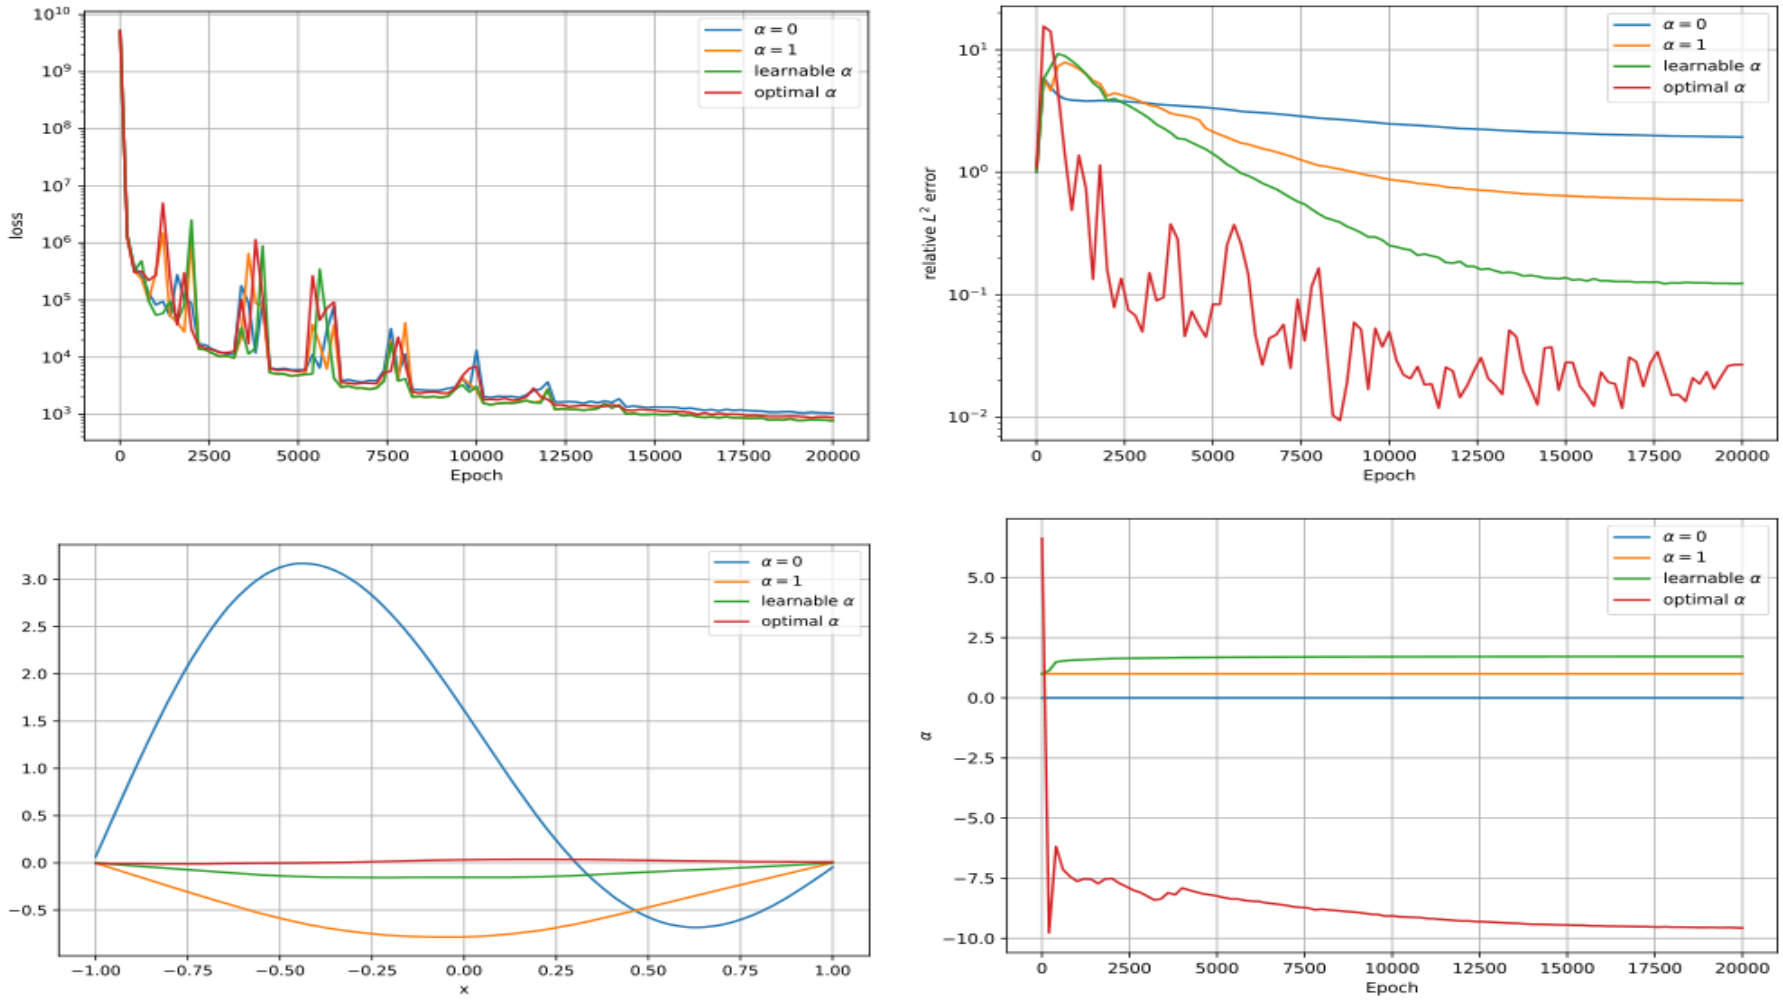

# 1D Poisson 方程求解的失败

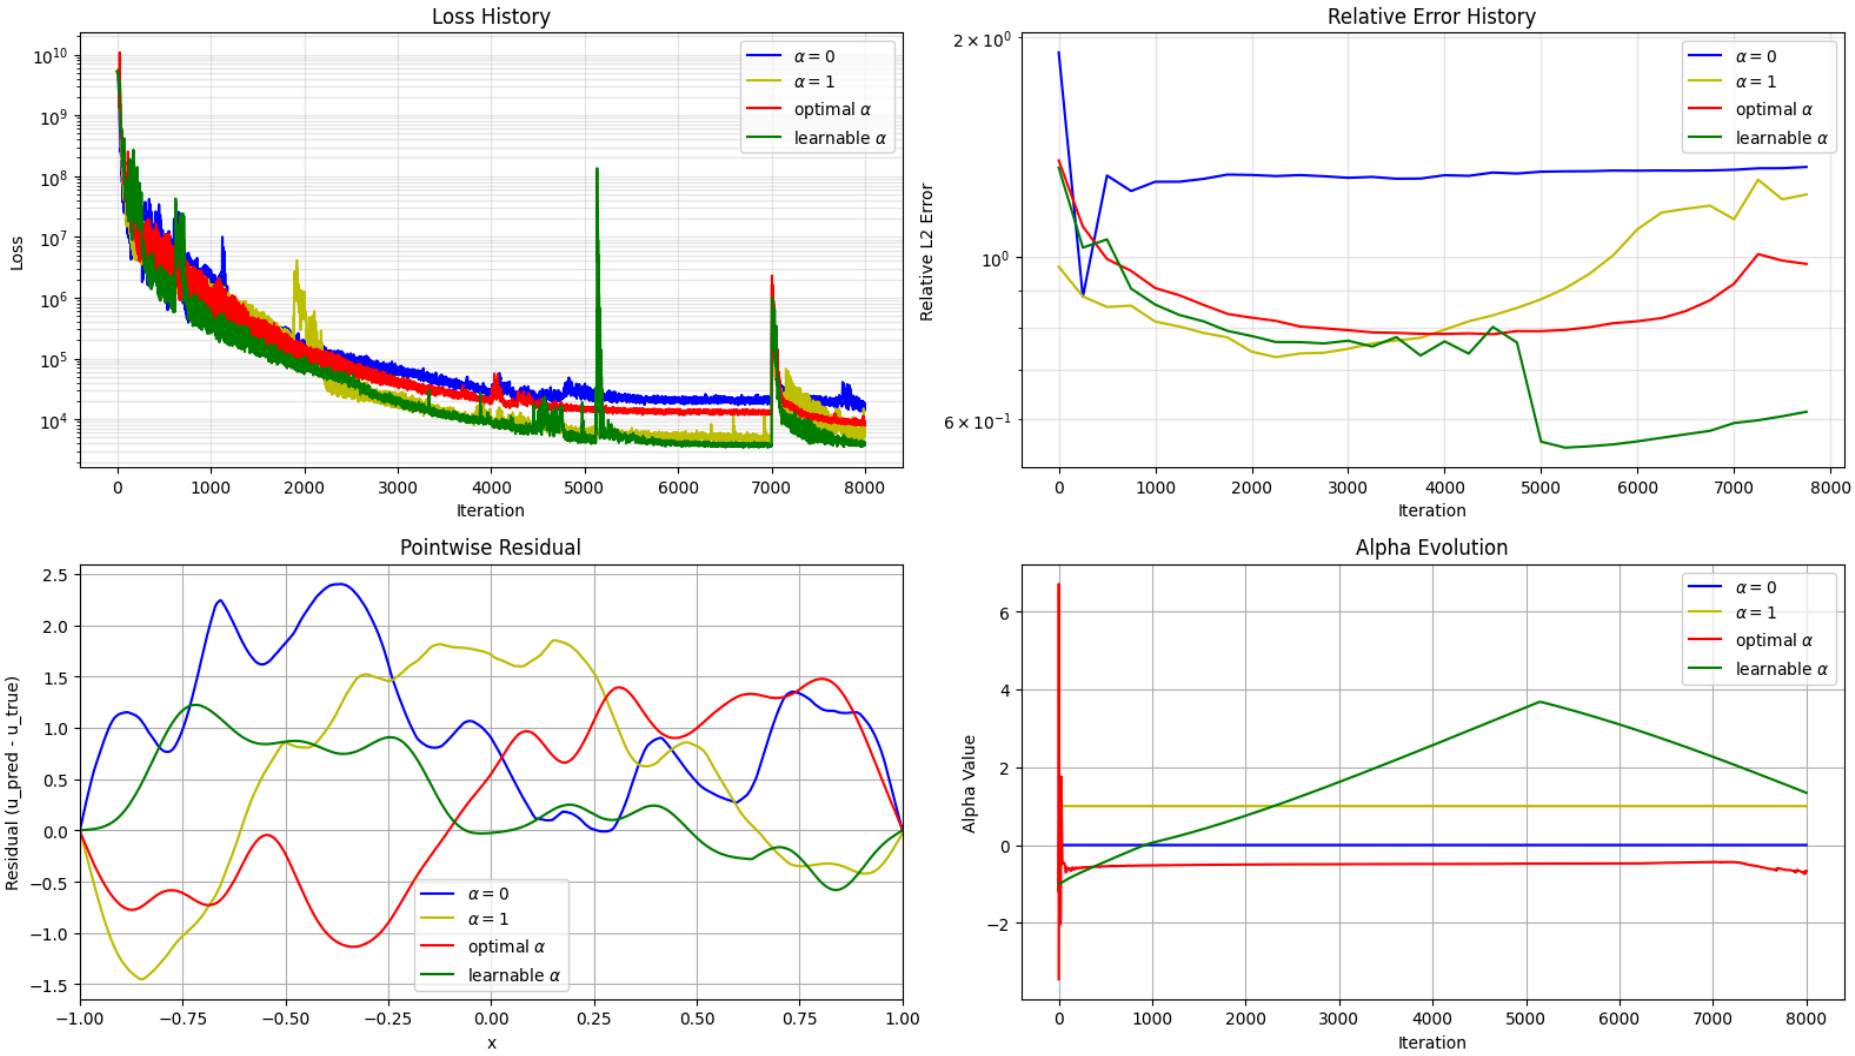

# 使用极简 RFF 神经网络求解

观察到上面的例子中的解是由简单正弦波叠加而成的，于是使用一个没有任何隐藏层的极简 RFF 神经网络来拟合这个解,即

$$u_{\text{pred}}(x) = \sum_{i=1}^{N} a_i \sin(\omega_i x + \varphi_i) + \text{bias}$$

$a_i$是模型权重(weights),设置$\omega, \varphi$均为可学习参数，总特征维数为512,每次训练使用 64 个配点，采用 PINN 的损失函数，用 Adam 优化器训练 1000 epoch 后训练结果见下图.

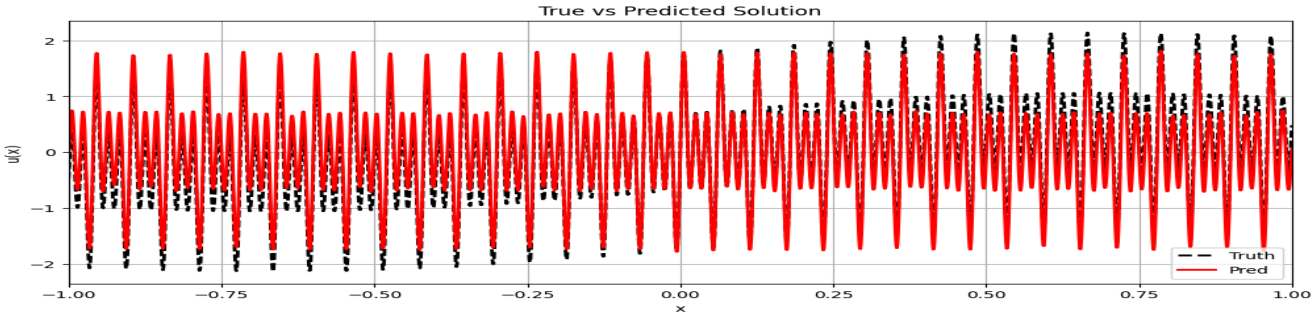

# 使用极简 RFF 神经网络求解

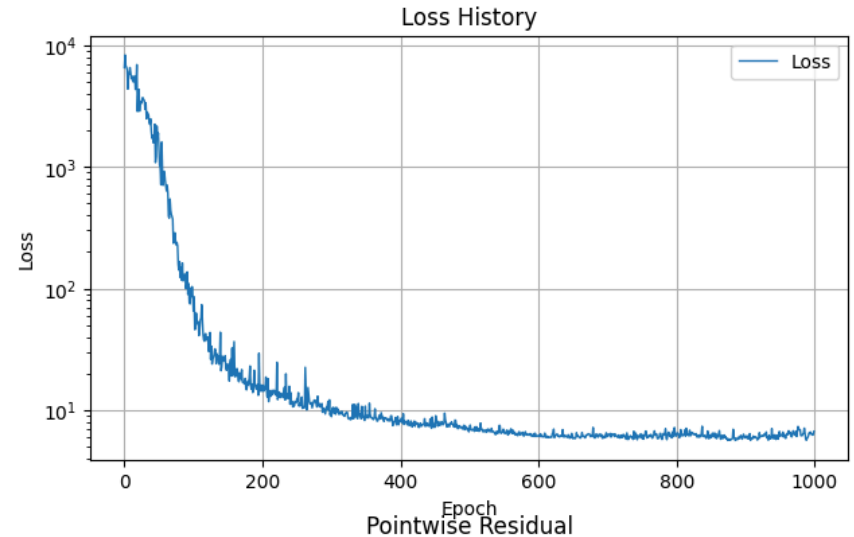


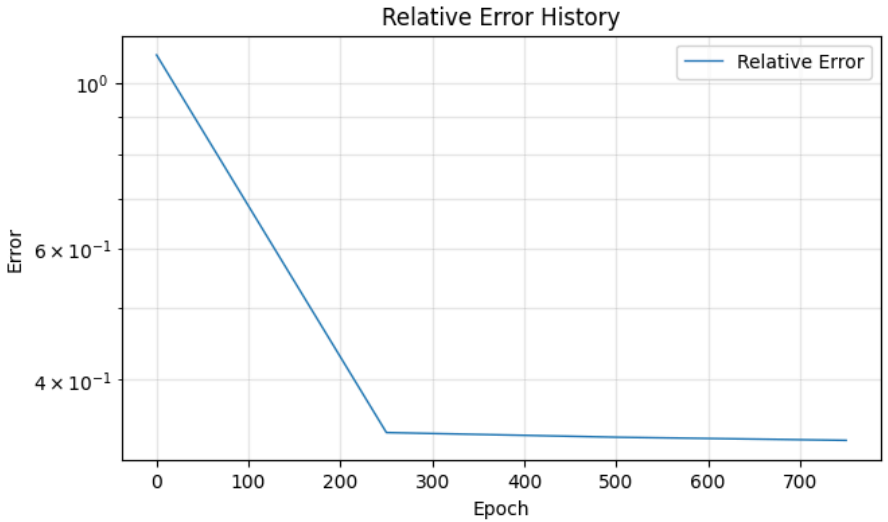


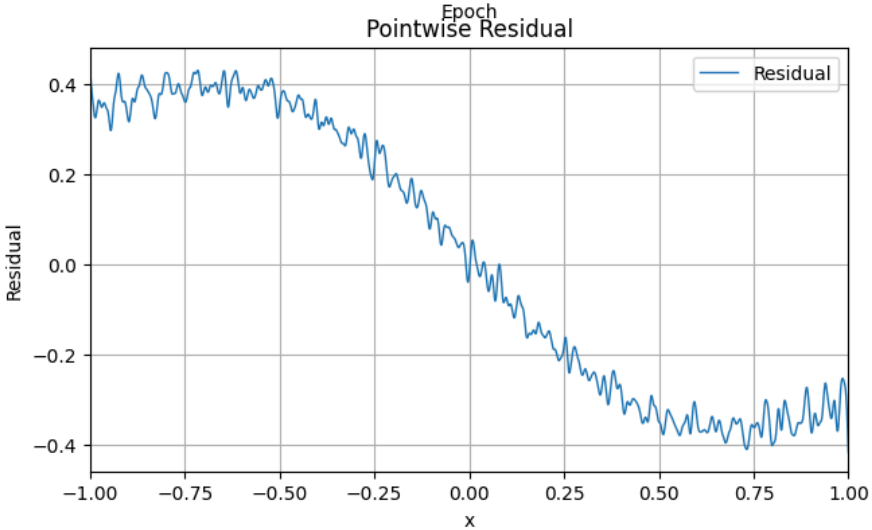

# 使用极简 RFF 神经网络求解

尽管这个模型非常简单,但它却非常快地在精度上超越了之前的复杂模型.然而，当我们尝试使用 4 层,宽 64,激活函数为 ReLU 的 MLP 神经网络拟合该网络输出解和真实解的 pde 残差,使用 Adam 优化器训练 1000 epoch 后,训练结果见下图.

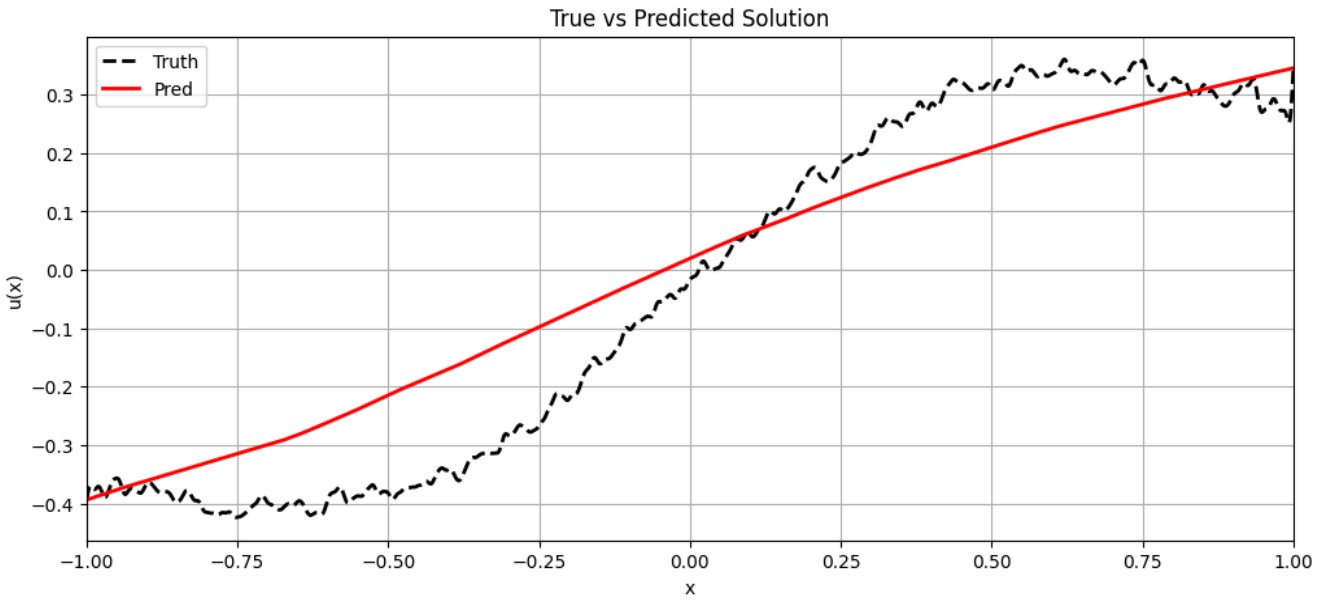

# 使用极简 RFF 神经网络求解

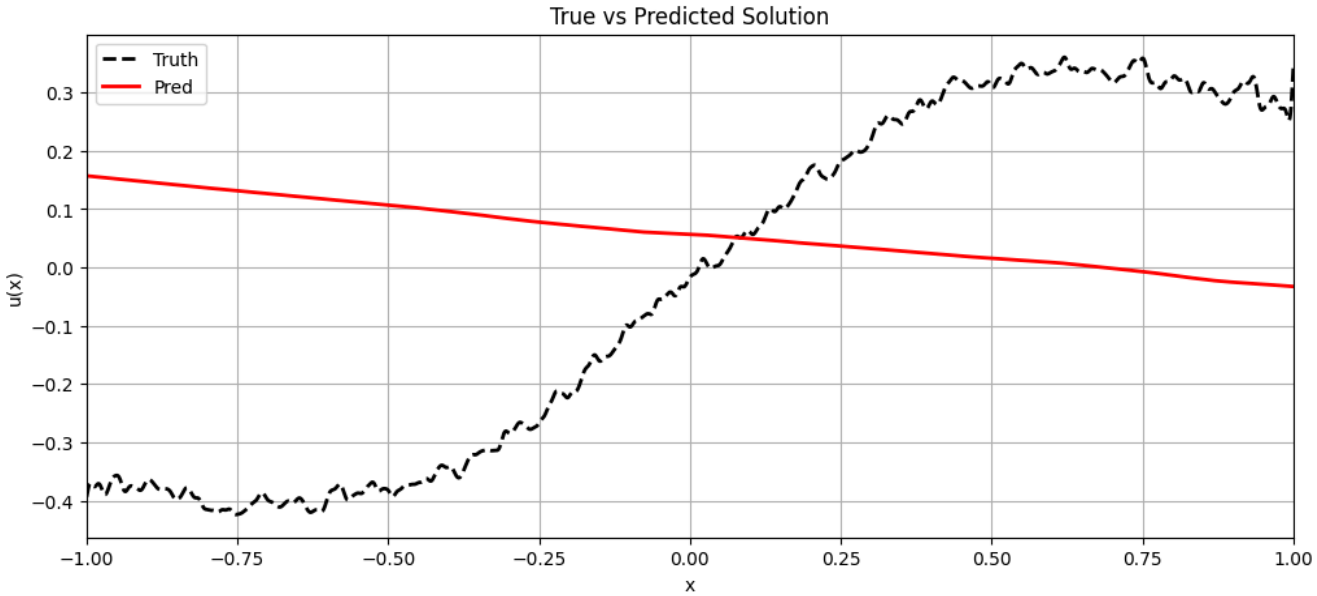


甚至彻底放弃边界条件，仍然无法拟合低频部分。

总结，该问题无法有效解决的原因是低频部分二阶导后的振幅过小,单靠物理约束的损失函数无法有效优化低频部分的拟合.

# 使用差分法代替自动微分

由于在训练过程中,模型需要计算二阶导数,使用自动微分极大降低了训练效率,因此我们尝试使用有限差分法来近似计算二阶导数.

我们认为神经网络的输出近似为真实解$u(x)$，我们使用七点中心差分计算二阶导数:

$$u_i'' \approx \frac{2u_{i-3} - 27u_{i-2} + 270u_{i-1} - 490u_i + 270u_{i+1} - 27u_{i+2} + 2u_{i+3}}{180h^2}$$

误差项为 $\left(-\frac{h^6}{560}u^{(8)}(\xi)\right)$ ,在数量级上$u^{(8)} \sim (100\pi)^8 \sin(100\pi x)$，不妨认为$\left|u^{(4)}(\xi)\right| \leq (100\pi)^4$.在[−1,1]上取 batch_size=10000 个点，此时$h = \frac{2}{10000}$,计算得 $\left|\left(-\frac{h^6}{560}u^{(8)}(\xi)\right)\right| \leq 1.1 \times 10^{-5}$.

这个误差远小于$u(x)$低频项$\sin(0.1\pi x)$的振幅$(0.1\pi)^2 \approx 0.099$.

# 使用差分法代替自动微分

实验显示，使用差分法后，模型的训练速度提升了一倍以上，Loss 曲线和使用自动微分时基本一致，证明了有限差分法在该问题上的有效性。